


# Local Minimum and Saddle Point

## 1. Critical Point (梯度为零的点)



在训练中，loss 不再下降，常见原因是：

- 梯度变得非常小 ( $\approx 0$ )
- 参数更新停住 (gradient descent 无法继续走)

此时我们可能来到所谓 **critical point**：

$$\nabla_{\theta} L(\theta) = 0$$

critical point 包含：

- **local minimum**
- **local maximum**
- **saddle point** (鞍点)

## 2. Taylor Series Approximation (泰勒展开)

loss 在某点  $\theta'$  附近可近似为：

$$L(\theta) \approx L(\theta') + (\theta - \theta')^T g + \frac{1}{2}(\theta - \theta')^T H(\theta - \theta')$$

其中：

- 梯度 (gradient)

$$g = \nabla_{\theta} L(\theta')$$

- Hessian (海森矩阵)

$$H_{ij} = \frac{\partial^2 L(\theta')}{\partial \theta_i \partial \theta_j}$$

在 critical point ( $g = 0$ ) 时：

$$L(\theta) \approx L(\theta') + \frac{1}{2}(\theta - \theta')^T H(\theta - \theta')$$

因此 Hessian 决定点的性质。

### 3. 用 Hessian 判断点的类型

设  $v \neq 0$ , 看二次型：

$$v^T H v$$

#### 3.1 Local Minimum 的条件

$$v^T H v > 0, \quad \forall v$$

等价于：

$$H \text{ positive definite} \iff \text{所有 eigenvalues} > 0$$

---

#### 3.2 Local Maximum 的条件

$$v^T H v < 0, \quad \forall v$$

等价于：

$H$  negative definite  $\iff$  所有 eigenvalues  $< 0$

---

### 3.3 Saddle Point 的条件

$v^T H v$  有时  $> 0$ 、有时  $< 0$

等价于：

$H$  indefinite  $\iff$  eigenvalues 有正有负

深度学习中最常出现的情况：saddle point，而不是 local minima。

## 4. 如何从 Saddle Point 逃离？

设  $u$  是 Hessian 的 eigenvector，对应 eigenvalue 为  $\lambda$ 。

$$Hu = \lambda u$$

代入二次项：

$$u^T Hu = \lambda \|u\|^2$$

若  $\lambda < 0$ ，则：

$$L(\theta' + u) < L(\theta')$$

表示沿着 eigenvector 的方向  $u$  移动，可以降低 loss。

更新方式概念上为：

$$\theta \leftarrow \theta' + \alpha u$$

(实际中不会这么做，因为计算 Hessian 代价极大)

## 4. Deep Learning: 为什么 Saddle Point 比 Local Min 更常见?

- 神经网络参数通常 百万到千万维
- Error surface 是高维空间形状
- 高维中“看似无路”的低维凹点往往只是 saddle, 而不是 local minima
- 在高维中, 存在大量下降方向 → local minima 很少

实验亦支持:

- 训练过程中卡住的点几乎都有 正负 eigenvalues 混合
- 真正所有 eigenvalues > 0 的情形很罕见

因此:

训练停住的原因几乎总是 saddle point, 而不是 local minimum。