

Batch Normalization

1. BN的动机：让 Error Surface 更好训练

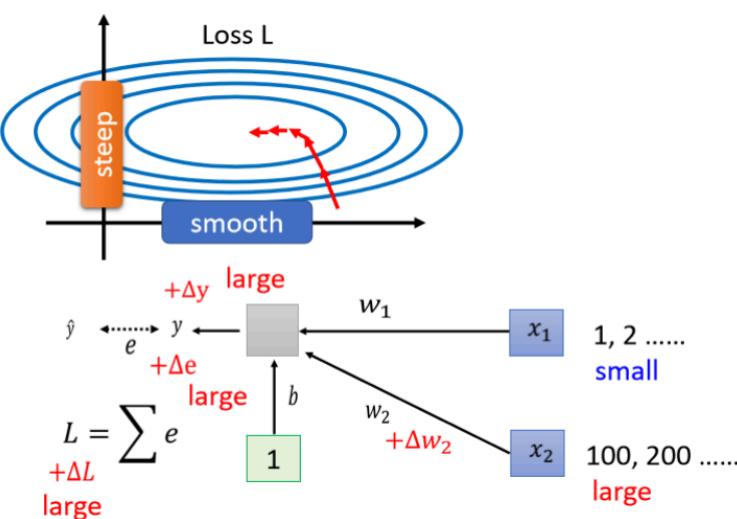
训练神经网络时，参数空间的不同方向斜率差异巨大，会造成：

- 某些方向梯度很小（走不动）
- 另一些方向梯度很大（震荡不收敛）

即使 error surface 是 convex，「不同方向的尺度不一致」也会造成训练困难。

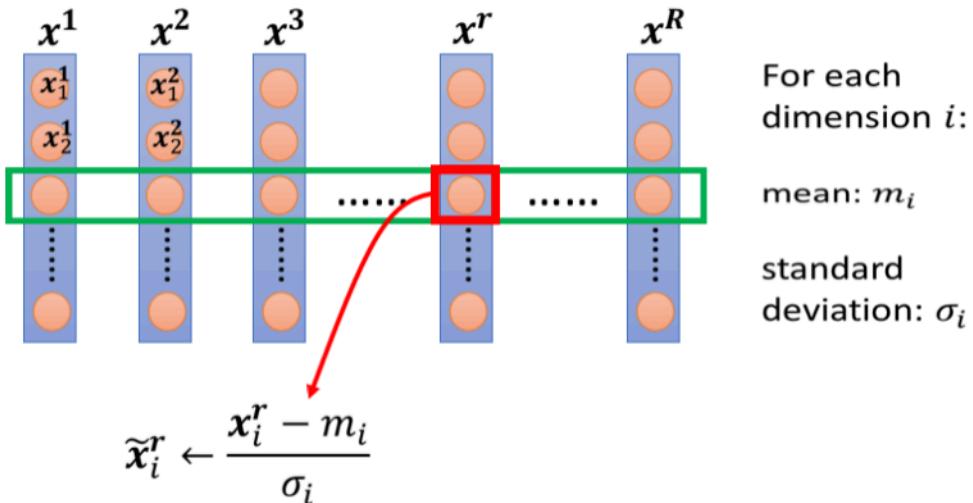
根本原因：

- 输入各维度的数值 **scale** 差异太大



通过归一化 feature，使各维度尺度一致，让 error surface 更平滑，更适合优化

2. Feature Normalization (BN 的概念基础)



对训练数据每个维度 i , 计算:

$$\mu_i = \mathbb{E}[x_i], \quad \sigma_i = \sqrt{\mathbb{E}[(x_i - \mu_i)^2]}$$

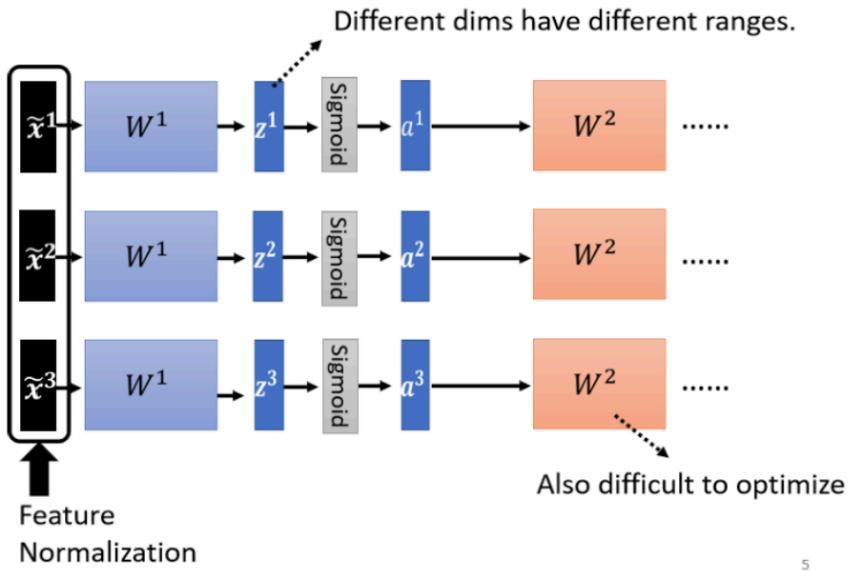
然后对每个样本做 standardization:

$$\tilde{x}_i = \frac{x_i - \mu_i}{\sigma_i}$$

这样:

- 每一维的 mean $\rightarrow 0$ 、variance $\rightarrow 1$
- 不同维度的scale被统一
- 训练更容易、收敛更快

3. 深度网络中的问题：中间层的z也需要 normalization



5

深度网络中: $z = Wx + b \Rightarrow a = \text{Activation}(z)$, 即便输入 x 被 normalize, 经过 W 后的 z 仍可能:

- 不同维度分布差异巨大
- 导致下一层训练困难

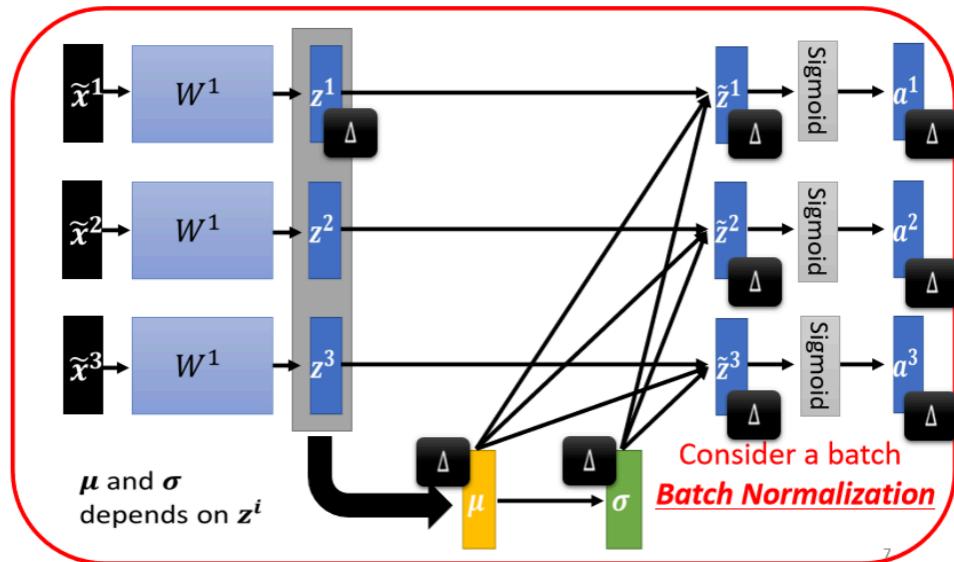
所以 Feature Normalization 应该放在: z (activation 前) 或 a (activation 后), 一般选择在 activation 前 (对 z 做 BN)

4. BN = Normalization + Learnable Shift & Scale

Considering Deep Learning

This is a large network!

$$\tilde{z}^i = \frac{z^i - \mu}{\sigma}$$



对一个 batch (大小=64, 例如) 中所有样本的同一维度, 计算: $\mu = \frac{1}{m} \sum_{i=1}^m z^{(i)}$, $\sigma = \sqrt{\frac{1}{m} \sum_{i=1}^m (z^{(i)} - \mu)^2}$, 对每个样本: $\tilde{z}^{(i)} = \frac{z^{(i)} - \mu}{\sigma}$

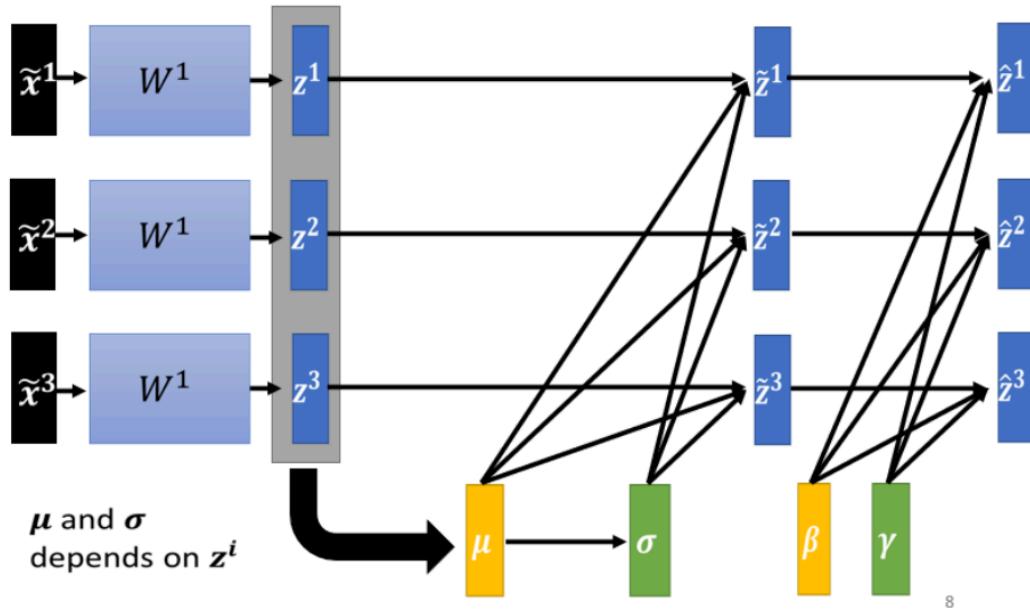
这就是 **Batch Normalization** 名字的来源:

| 只利用当前 batch 的数据估计 mean/variance

Batch normalization

$$\tilde{z}^i = \frac{z^i - \mu}{\sigma}$$

$$\hat{z}^i = \gamma \odot \tilde{z}^i + \beta$$



- Normalization 会强制 mean=0、std=1，但模型可能需要不同分布

所以引入 learnable 参数: $y = \gamma \tilde{z} + \beta$

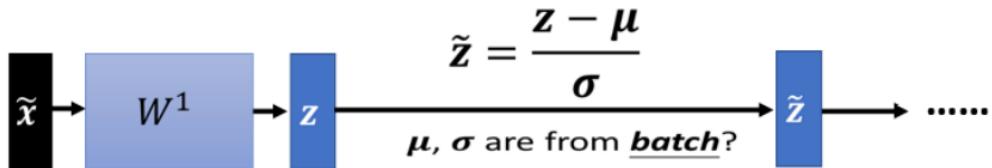
其中：

- γ 初值 = 1
- β 初值 = 0

确保初期模型行为与未使用 BN 相近。

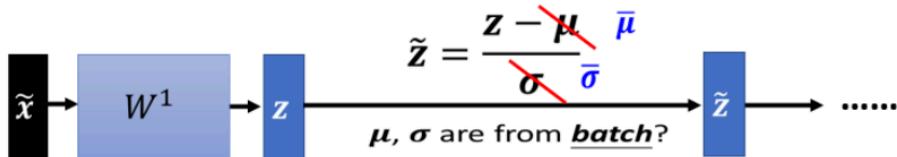
训练过程中 γ 与 β 会被学习，用于恢复或调整分布。

5. Testing (Inference) 阶段如何处理 BN?



- 测试时：

- 不会等待“凑满一个 batch”再计算 mean & variance
- 必须独立处理每一笔样本
- 解决方式 (PyTorch、TensorFlow 都是这样做的) :



We do not always have **batch** at testing stage.

Computing the moving average of μ and σ of the batches during training.

$$\mu^1 \quad \mu^2 \quad \mu^3 \quad \dots \quad \mu^t$$

$$\bar{\mu} \leftarrow p\bar{\mu} + (1-p)\mu^t$$

在训练过程中维持 moving average:

$$\mu_{\text{running}} = p \cdot \mu_{\text{running}} + (1-p) \cdot \mu_{\text{batch}}$$

$$\sigma_{\text{running}} = p \cdot \sigma_{\text{running}} + (1-p) \cdot \sigma_{\text{batch}}$$

测试阶段使用:

$$\tilde{z} = \frac{z - \mu_{\text{running}}}{\sigma_{\text{running}}}$$

测试时 BN 不依赖 batch, 而是依赖训练时累积的 running mean / variance。